Московский Государственный Университет им. Ломоносова

Факультет Вычислительной Математике и Кибернетики

Сегментация изображений с помощью нейронной сети U-Net

Юдина Диана

217 группа

Москва

2025

Содержание

Введение

Сегментация изображений - разбиение изображения на множество покрывающих его областей. Сегментация изображений используется во многих областях: медицина, геология, астрономия и т.д. В это проекте мы рассматриваем сегментацию рудных металлов с помощью сверточной нейросети U-Net.

Почему именно U-Net ?

Изначально для сегментации изображений выбор пал на кластеризацию (KMeans) , так как это классический метод, так как это простой, точный и быстрый метод для обработки, но к сожалению, не давал больших показателей. Поэтому было принято решение перейти более к сложной модели - сверточной нейронной сети U-Net, которая показала высокие показатели оценки mean iou, точность, но заняла долгое обучение модели и сложность в написании.

Архитектура сверточной нейронной сети U-Net

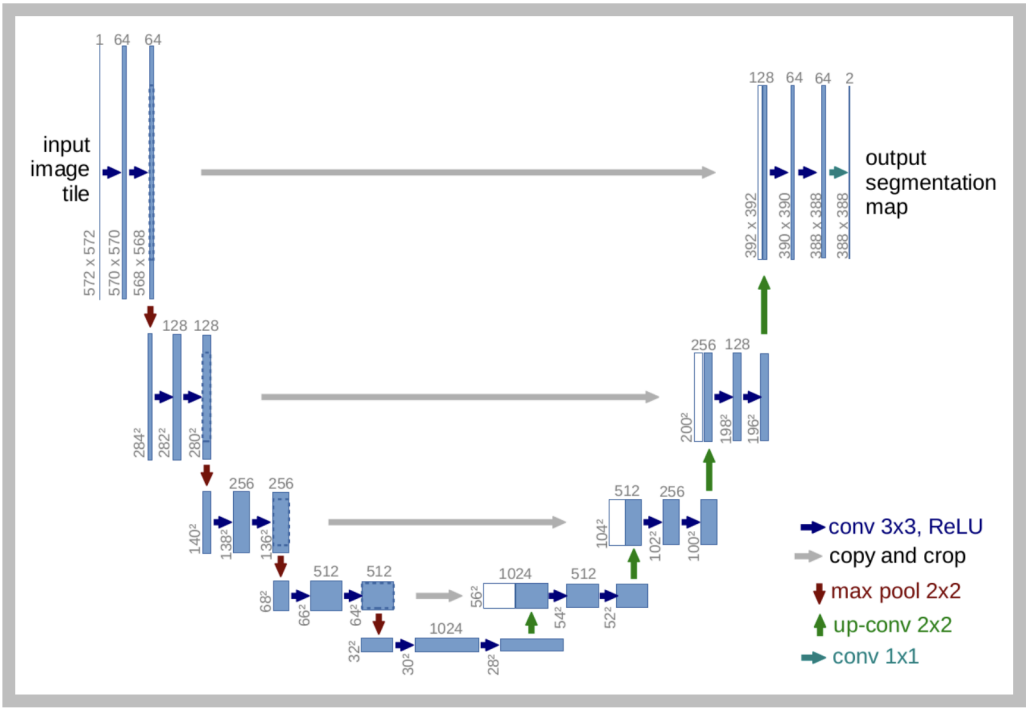

U-Net architecture as proposed by Ronneberger et al. (2015).

Encoder (Contracting Path)

Основной задачей Encoder (энкодера, сжимающего пути) является уменьшение размера фотографий с выделением важных признаков, которое позволяет уменьшить пространственное разрешение. В свою очередь сжимающий путь тоже состоит из нескольких частей:

- **Convolutional Layers** (сверточные слои)

  Каждый блок содержит два последовательных 3×3 сверточных слоя с функцией активации ReLU

- **Pooling Layers** (субдискретизация)

  Pooling уменьшает размер изображений 2 раза и помогает конкретизировать информацию и уменьшить вычислительную сложность работы модели.

- **Increasing the number of filter features** (увеличение числа фильтров)

  По мере движения модели, количество фильтров удваивается (64 -> 128 -> 256 и т.д). Это помогает еще больше больше конкретизировать признаки и работать с более сложными данными

Decoder (Expanding Path)

Основной задачей Decoder (восстанавливающей частью, декодером) является восстановление исходного размера, используя информацию из сжимающего путь , т.е те самые признаки, которые он выделял на каждом этапе, а также точно определить границы объектов. В свою очередь decoder тоже состоит из нескольки частей:

- **Upsampling, Transposed Convolution**

  Увеличивает размер изображений в 2 раза

- **Skip Connections**

  Skip Connections (прямые соединения) является одной из ключевых этапов в использование нейросети U-Net. Это этап

соединения Encoder и Decoder, который позволяет восстановить мелкие детали, которые могли быть утеряны в процессе работы модели.

- **Convolutional Layers**

  После Skip Connections, выполняются два сверточных слоя с ReLU, это помогает применить признаки, которые мы выделяли ранее с пространственному расширению.

Проект

Проект выполнен в поддержку спецкурса “Практическое введение анализ изображений”.

Основные атрибуты:

- Язык программирования Python
- Импорт библиотеки petroscope
- DataSet: https://drive.google.com/drive/folders/1eYvegx54xDZkHWwmG6Jrr57sGAUYaR4p?usp=share_link
- Метод, используемый для сегментации изображений: нейронная сеть U-Net

В репозитории https://github.com/DianaY23/Image-analysis.git :

1. Файл project.pynb - from Google Collab
2. Файл project.py - python file
3. Файл project.ipynb - Colab.pdf
4. Файл outputs.txt - выходные данные для выборки test

Ссылка на google collab
https://colab.research.google.com/drive/1A_Fh04m-F-vEu6mBQDIkwk2PFmJAP1tC?usp=sharing

Программная реализация

1. GeoSegmModel

Библиотека petroscope, предоставляет удобные инструменты для геологической сегментации, включая *GeoSegmModel*, который можно расширить для создания кастомной модели сегментации.

2. Модель U-Net

```
def _build_model(self):
       inputs = Input(self.input_size)

                    conv1   =   Conv2D(64,   3,   activation='relu',
padding='same')(inputs)
                    conv1   =   Conv2D(64,   3,   activation='relu',
padding='same')(conv1)
       pool1 = MaxPooling2D(pool_size=(2, 2))(conv1)
                   conv2   =   Conv2D(128,   3,   activation='relu',
padding='same')(pool1)
                   conv2   =   Conv2D(128,   3,   activation='relu',
padding='same')(conv2)
       pool2 = MaxPooling2D(pool_size=(2, 2))(conv2)
                   conv3   =   Conv2D(256,   3,   activation='relu',
padding='same')(pool2)
                   conv3   =   Conv2D(256,   3,   activation='relu',
padding='same')(conv3)
       pool3 = MaxPooling2D(pool_size=(2, 2))(conv3)
                   conv4   =   Conv2D(512,   3,   activation='relu',
padding='same')(pool3)
                   conv4   =   Conv2D(512,   3,   activation='relu',
padding='same')(conv4)

        up5 = concatenate([UpSampling2D(size=(2, 2))(conv4), conv3],
axis=-1)
                   conv5   =   Conv2D(256,   3,   activation='relu',
padding='same')(up5)
                   conv5   =   Conv2D(256,   3,   activation='relu',
padding='same')(conv5)
        up6 = concatenate([UpSampling2D(size=(2, 2))(conv5), conv2],
axis=-1)
                   conv6   =   Conv2D(128,   3,   activation='relu',
padding='same')(up6)
```

```
                    conv6   =   Conv2D(128,   3,   activation='relu',
padding='same')(conv6)
        up7 = concatenate([UpSampling2D(size=(2, 2))(conv6), conv1],
axis=-1)
       conv7 = Conv2D(64, 3, activation='relu', padding='same')(up7)
                      conv7   =   Conv2D(64,   3,   activation='relu',
padding='same')(conv7)

                         outputs    =    Conv2D(len(self.classes),    1,
activation='softmax')(conv7)

       model = Model(inputs=[inputs], outputs=[outputs])
                                        model.compile(optimizer=Adam(),
loss='categorical_crossentropy', metrics=['accuracy'])
       return model
```

Алгоритм реализации функции def _build_model

1. Создаем входной слой модели U-Net, которая принимает изображения размером (256, 256, 3) - где 3 - количество каналов
2. Далее выполняются действия Encoder. В начале работаем с двумя слоями свертки, которые выполняют извлечение признаков. У каждого слоя 64 фильтра, ядро 3x3.
3. Выполняем Pooling, уменьшение размера изображения происходит в два раза. Это поможет уменьшить вычислительную нагрузку, меньше загрузить ОЗУ и , самое главное, извлечь более признаки.
4. На следующем этапе снова выполняется свертка, аналогичная в п.2, но уже с 128 фильтрами (согласно архитектуре нейросети U-Net).
5. Совершаем Pooling, аналогичный п.3, но уже для новых слоев свертки.
6. П.2 с 256, 512 фильтрами

7. Pooling для новых слоев с еще большим уменьшением размера изображений и выявлением новых признаков.
8. Далее выполняется работа уже Decoder. Выполняем увеличение разрешения изображения.
9. Выполняем Skip Connection , т.е объединяем результаты слоя Encoder и Decoder. Так мы сможем сохранить информацию о признаках, которые мы вывели ранее
10. Далее , согласно архитектуре U-Net, выполняем Upsampling. И конкатенируем результаты с Encoder, чтобы запомнит детали, которые могли быть потеряны во время сжатия. И применяем два слоя свертки с 256 фильтрами, аналогичные действия п.8 выполняем для 128, 64 фильтров.
11. Выполняем свертку 1x1 чтобы получить результат сегментации.
12. Далее “собираем” нашу модель

Заключение

В ходе данного проекта был изучен метод сегментации изображений - нейронная сеть U-Net, а также была реализована задача сегментации рудных минералов.

Архитектура U-Net является одной из наиболее популярных и новых моделей на сегодняшний день. Данная модель позволяет добиться высокой точности показателя mean iou, а также предоставляет работу с большим количеством данных.

Литература

1. Исследование применимости сверточной нейронной сети U-Net к задаче сегментации изображений авиационной техники, *Д.А. Гаврилов* https://repo.ssau.ru/bitstream/Zhurnal-Komputernaya-optika/Issledovanie-primenimosti-svertochnoi-neironnoi-seti-UNet-k-zadache-segmentacii-izobrazhenii-aviacionnoi-tehniki-90778/1/450412.pdf?ysclid=m8vejt64di873994401

2. U-Net: Convolutional Networks for Biomedical Image Segmentation, https://borea17.github.io/paper_summaries/u_net/

3. Multi-Encoder U-Net for Automatic Kidney Tumor Segmentation, Xueying Chen1 and Chao Xu, https://kits-challenge.org/public/site_media/manuscripts/kits19/cxyjy_3.pdf

4. Simonyan K., Zisserman A. *Very Deep Convolutional Networks for Large-Scale Image Recognition* https://arxiv.org/pdf/1409.1556

5. Goodfellow I., Bengio Y., Courville A. *Deep Learning* // MIT Press. – 2016. https://bjpcjp.github.io/pdfs/dl-goodfellow/toc.pdf